

Entregable 3 — Matriz de Optimización de Costos

Justificación de qué modelo se usa por tarea, comparación con alternativas y ahorro estimado — Proyecto ADC Triage

El flujo hace dos llamadas de IA por consulta, y cada una usa un modelo distinto de Groq elegido a propósito según qué tan exigente es la tarea — no se usó el mismo modelo grande para todo. Esta sección justifica esa elección con precios reales y compara contra alternativas de OpenAI y Anthropic para mostrar el ahorro.

1. Modelo usado por tarea (elección real del proyecto)

Tarea	Modelo elegido	Por qué este modelo	Precio (Groq)
Clasificar consulta (categoría + prioridad)	Groq Llama-3.1-8B-Instant	Tarea simple y acotada: devolver 2 campos de un JSON corto. No requiere razonamiento profundo, así que el modelo más chico y más barato alcanza. Max Tokens limitado a 200 y temperature 0.1 (respuesta determinística).	Input \$0.05 /1M Output \$0.08 /1M
Redactar respuesta (con contexto RAG)	Groq Llama-3.3-70B-Versatile	Tarea de lectura densa: tiene que leer varias directrices privadas, entender cuál aplica, y redactar un email coherente en tono ADC. Acá sí conviene un modelo más grande. Max Tokens 500, temperature 0.5.	Input \$0.59 /1M Output \$0.79 /1M

Precios de Groq relevados el 18-ago-2026 (ver fuentes al final del documento). Además, la arquitectura ya ahorra una llamada cara por diseño: si la IA clasifica la consulta como “Otro”, el flujo la descarta antes de llegar al modelo de 70B — nunca se paga la redacción de algo que no correspondía procesar.

2. Costo estimado por consulta procesada

Con supuestos conservadores de tamaño de prompt (system message + email ≈ 400 tokens de entrada para clasificar; email + contexto RAG ≈ 900 tokens de entrada para redactar; salidas reales bien por debajo del límite configurado):

Paso	Input est.	Output est.	Costo del paso
Clasificar (8B)	400 tok	40 tok	≈ US\$ 0,000023
Redactar (70B)	900 tok	350 tok	≈ US\$ 0,000807
Total por consulta (Comercial / Soporte Técnico)	—	—	≈ US\$ 0,00083
Total por consulta descartada como “Otro” (solo clasifica)	—	—	≈ US\$ 0,000023

3. Comparación contra alternativas (mismo prompt, mismo volumen)

Tarea	Alternativa	Precio /1M tok (in / out)	Costo del paso	vs. elegido
Clasificar	Groq Llama-3.1-8B (elegido)	\$0,05 / \$0,08	US\$ 0,000023	base
Clasificar	OpenAI GPT-4o-mini	\$0,15 / \$0,60	US\$ 0,000084	≈ 3,6× más caro

Tarea	Alternativa	Precio /1M tok (in / out)	Costo del paso	vs. elegido
Clasificar	Claude Haiku 4.5	\$1 / \$5	US\$ 0,0006	≈ 26× más caro
Redactar	Groq Llama-3.3-70B (elegido)	\$0,59 / \$0,79	US\$ 0,000807	base
Redactar	OpenAI GPT-4o-mini	\$0,15 / \$0,60	US\$ 0,000345	≈ 2,3× más barato*
Redactar	Claude Sonnet 5	\$2 / \$10	US\$ 0,0053	≈ 6,6× más caro

* Nota honesta: en pura tarifa por token, GPT-4o-mini sale incluso más barato que Llama-3.3-70B para redactar. No lo elegimos igual por dos razones prácticas del proyecto: (1) todo el stack ya corre sobre la cuenta de Groq configurada para el curso, evitando manejar una credencial y un proveedor más; y (2) Llama-3.3-70B mostró mejor adherencia al “usó exclusivamente el contexto RAG, no inventes” en las pruebas. Si el volumen creciera mucho, vale la pena re-testear GPT-4o-mini para redactar, ya que el ahorro es real.

4. Ahorro estimado por volumen mensual

Consultas / mes	Stack elegido (Groq 8B+70B)	Si todo fuera Claude Sonnet 5	Ahorro
500	US\$ 0,42	US\$ 3,25	US\$ 2,83 (≈ 87%)
2.000	US\$ 1,66	US\$ 13,00	US\$ 11,34 (≈ 87%)
10.000	US\$ 8,31	US\$ 65,00	US\$ 56,69 (≈ 87%)

(La columna “Si todo fuera Claude Sonnet 5” usa Sonnet 5 tanto para clasificar como para redactar, como punto de referencia superior. Supone además que el 100% de las consultas llega a redacción — el escenario más caro posible; en la práctica una parte se descarta como “Otro” en la etapa de clasificación y el ahorro real es mayor.)

5. Cuándo usar Batches API en vez de llamadas en tiempo real

El triage de ADC necesita respuesta rápida porque un humano tiene que aprobar en Slack antes de que se le conteste al cliente, así que las llamadas van en tiempo real. Pero si más adelante ADC quisiera, por ejemplo, reclasificar en bloque miles de consultas históricas para entrenar un mejor prompt, o generar reportes de categorización masivos donde no importa esperar unas horas, ahí sí conviene la Message Batches API de Anthropic — **50% de descuento** en input y output tanto para Claude Haiku 4.5 (US\$ 0,50 / US\$ 2,50 por millón de tokens) como para Claude Sonnet 5 (US\$ 1 / US\$ 5), procesando de forma asíncrona. Es la misma lógica de costos que se trabajó en la Pre-entrega 5 del curso (Batches API + Prompt Caching para procesos masivos).

Fuentes de precios (relevadas 18-ago-2026)

- Groq — Llama-3.1-8B-Instant y Llama-3.3-70B-Versatile: cloudzero.com/blog/groq-pricing y easel.ai/blog/groq-pricing (cifras cruzadas entre ambas fuentes, coinciden).
- OpenAI — GPT-4o-mini: pricepertoken.com/pricing-page/model/openai-gpt-4o-mini
- Anthropic — Claude Haiku 4.5 / Sonnet 5 y Message Batches API (50% off): platform.claude.com/docs/en/about-claude/pricing